

GPU 功耗与性能预测挑战

背景

大语言模型（LLM）的推理部署是 AI 基础设施中最核心的工程挑战之一。每一次用户请求，GPU 都在消耗电力、产生延迟——而这两者直接决定了数据中心的运营成本 and 用户体验。

想象你是一家 AI 云计算公司的能效架构师。你的老板甩给你一张表：上面记录了各种 GPU 型号、不同 LLM 模型、在不同请求负载下的实测功耗和延迟数据，然后问你——

"给定硬件规格、模型参数、以及预期的请求量，我们能不能提前算出来这台机器要花多少电、有多快？"

这就是你要解决的问题。

本数据集来源于学术论文 *Watt Counts: An Empirical Study of GPU Power Consumption and Performance in LLM Inference*，包含了 8 种数据中心级 GPU、30+ 种开源 LLM、在离线批处理和在线服务两种场景下的数千次实测数据。你的任务是基于 **硬件规格 + 模型参数 + 运行负载** 这三个维度的输入，**同时预测四个核心性能指标**。

任务定义

输入 (X)：每条实验记录的以下特征——

维度	特征	说明
运行负载	lambda_qps	请求到达率（每秒查询数），-1 表示离线批处理
运行负载	scenario	运行场景： offline / server_low / server_high
运行负载	avg_prompt_tokens	平均每条请求的输入 Token 数
运行负载	avg_generation_tokens	平均每条请求的输出 Token 数
运行负载	num_requests	该实验包含的请求数量
模型参数	total_b_params	模型总参数量（十亿）
模型参数	num_layers	Transformer 层数

维度	特征	说明
模型参数	hidden_size	隐藏层维度
模型参数	num_attention_heads	注意力头数
模型参数	num_key_value_heads	KV 头数（GQA 相关）
模型参数	model_type	模型架构家族（如 llama 、 qwen2 等）
硬件规格	memory_size_gb	GPU 显存容量（GB）
硬件规格	release_year	GPU 发布年份
硬件规格	base_clock_mhz	GPU 基础频率（MHz）
硬件规格	boost_clock_mhz	GPU 加速频率（MHz）
硬件规格	architecture	GPU 架构名称
硬件规格	memory_type	显存类型（HBM2e / GDDR6 等）

输出 (y)：四个连续数值标签——

标签	含义	单位	业务价值
gpu_power_draw_watts	GPU 平均功耗	瓦特 (W)	数据中心电费预估
avg_e2e_latency_seconds	平均端到端延迟	秒 (s)	用户体验评估
energy_efficiency_tokens_per_joule	能效比（每焦耳生成 Token 数）	Token/J	"绿色 AI" 核心指标
throughput_tokens_per_second	系统吞吐量（每秒生成 Token 数）	Token/s	服务容量评估

这是一个**多目标回归**任务。你需要构建一个模型，能够从硬件、模型和负载三个维度出发，同时预测功耗、延迟、能效和吞吐量这四个关键指标。

数据集

数据来源

数据来源于 *Watt Counts* 论文中的 Watt Counts Subset 实验集，在多种 GPU（Tesla T4 到 H200 NVL）上测试了 30+ 种开源 LLM（从 GPT-2 124M 到 Gemma-3 27B）在离线批处理和在线服务场景下的真实推理性能。

文件说明

文件	说明
train.csv	训练集，包含特征列 + 4 个标签列
A.csv	A 榜测试集， 仅包含特征列，无标签
B.csv	B 榜测试集， 仅包含特征列，无标签
baseline.ipynb	参赛者基线 Notebook，提供入门参考
Paper_Watt_Counts.pdf	<i>Watt Counts</i> 原始论文

数据特征

- 训练集、A 榜、B 榜按 70:15:15 随机分割。
- **训练集存在 GPU 不平衡**：高端稀缺显卡（如 H200、H100、A100）在训练集中的样本被有意削减，模拟真实场景中昂贵硬件数据稀缺的情况。常见显卡（T4、L4、L40S）数据充足。
- A 榜和 B 榜测试集保持均衡，所有 GPU 类型均有充分代表。
- 数据跨度极大——从 0.5B 参数的小模型在低端 GPU 上的低功耗场景，到 27B 大模型在 H200 上的高吞吐场景。
- 部分数据存在离线模式（`lambda_qps = -1`），表示连续批处理，无请求间隔。

评价指标

本任务采用**综合评分**，由以下两个指标加权得到：

主要指标： R^2 （决定系数）

对于每个目标变量 i ，计算：

$$R^2_{*i} = 1 - \frac{\sum_j (y_{*ij} - \hat{y}_{*ij})^2}{\sum_j (y_{*ij} - \bar{y}_{-i})^2}$$

四个目标的 R^2 取平均作为主要得分（范围 0~1）：

$$\text{Primary Score} = \frac{1}{4} \sum_i R_i^2$$

得分**越高越好**（1.0 为完美预测）。

辅助指标：WMAPE（加权平均绝对百分比误差）

$$\text{WMAPE}_i = \frac{\sum_j |y_{*ij} - \hat{y}_{*ij}|}{\sum_j |y_{*ij}|} \times 100\%$$

四个目标的 WMAPE 取平均作为辅助参考（越低越好）。

提交格式

你需要提交一个 CSV 文件，命名为 `A_predict.csv`（A 榜）或 `B_predict.csv`（B 榜），格式如下：

```
gpu_power_draw_watts,avg_e2e_latency_seconds,energy_efficiency_tokens_per_joule,throughput_token
163.42,0.0487,27.68,4567.2
45.12,0.0125,18.34,892.1
...
```

- 顺序必须与测试集完全一致（第一行预测对应 `A.csv` / `B.csv` 的第一行）
- 列名必须完全匹配上述四个标签名
- 不需要包含行索引或 ID 列

约束条件

为了确保比赛的公平性，请遵守以下限制：

约束项	限制
预训练模型	禁止使用任何预训练权重（包括在非公开数据上训练的）
大语言模型 API	禁止调用任何 LLM API（如 GPT-4、Claude 等）

约束项	限制
第三方库	仅限 NOAI 考纲内库 (numpy 、 pandas 、 scikit-learn 、 torch 、 xgboost 、 lightgbm 等)
外部数据	可以使用公开的 GPU / LLM 规格数据， 但 严禁使用本数据集的任何外部副本或变体

参考资料

- 1. [Watt Counts: An Empirical Study of GPU Power Consumption and Performance in LLM Inference](#)
— 本数据集的原始论文
- 2. *LLM Inference Performance Engineering* — NVIDIA 技术博客系列
- 3. *Roofline Model* — 经典性能分析模型

许可

本数据集和题目采用 [CC BY-NC-SA 4.0](#) 许可协议。