

GPU功耗预测：当 AI 开始操心电费账单

"给你一张 GPU 的体检报告和一份模型的简历，你能算出这台机器会烧多少电、跑多快吗？"
——欢迎来到 GPU 功耗与性能预测挑战，让你足不出户，体验一把数据中心能效架构师的日常。



"从硬件参数到电费账单——AI 能效分析师正式上岗。"

题目简介

你是一家 AI 云计算公司的能效架构师。老板甩给你一堆实验记录——记录了各种 GPU 型号跑各种 LLM 模型在不同请求负载下的实际表现。现在他要你：

不看实测结果，只看"配置单"，就能预测功耗、延迟、能效和吞吐量。

- **输入：**24+ 个特征，涵盖运行负载（QPS / Token 数）、模型参数（参数量 / 层数 / 隐藏维度）、硬件规格（带宽 / 算力 / TDP）
- **输出：**4 个连续数值——GPU 功耗、端到端延迟、能效比、吞吐量
- **数据来源：**Watt Counts 论文的实证数据集，8 种 GPU × 30+ 种 LLM × 离线/在线两种场景
- **训练集：**数千条实测记录，特征 + 4 个标签全给你
- **A 榜测试集：**只给特征，让你悄悄验证模型
- **B 榜测试集：**只给特征，最终评分全靠它

🧐 **温馨提示：**不要试图手工推导——H200 跑 7B 模型的功耗和 T4 跑 1.5B 模型的延迟，这两者之间的物理规律比高数课本还复杂。把这事交给机器学习吧。

如果你觉得"不就是个回归吗"，恭喜你——你已经具备了轻敌的所有条件。训练集中高端显卡（H200、H100）的数据故意砍掉大半——毕竟现实中谁没事拿 H200 做实验啊？不过别担心，A/B 榜是均衡的。



评分标准：R² + WMAPE —— 四项全能才拿金牌

这是一道"偏科禁止"的题。你需要同时预测四个目标，缺一则败。

主指标：R²（决定系数）

$$R_i^2 = 1 - \frac{\sum_j (y_{ij} - \hat{y}_{ij})^2}{\sum_j (y_{ij} - \bar{y}_i)^2}$$

四个目标的 R² 取**平均**作为主得分。**越高越好**，范围 0~1，1.0 = 完美（别想了）。

辅助指标：WMAPE（加权平均绝对百分比误差）

$$\text{WMAPE}_i = \frac{\sum_j |y_{ij} - \hat{y}_{ij}|}{\sum_j |y_{ij}|} \times 100\%$$

四个目标的 WMAPE 取平均作为辅助参考。**越低越好**，0% = 完美。

 **目标：**让你的模型成为"GPU 算命师"——掐指一算，功耗延迟全知道。偏科某一项？不好意思，总分教你做人。

约束条件（"违反任意一条，罚款 100000000 度电"）

-  **不准用预训练权重**（ImageNet / 任何其他数据集上训过的模型都不行）。必须从零开始训练。
-  **不准调戏大模型 API**（GPT、Claude、文心一言……它们的物理直觉可能还不如你）。
-  **只允许 NOAI 考纲内的库**（numpy、pandas、scikit-learn、torch、xgboost、lightgbm 等，别掏出来路不明的第三方轮子）。
-  **严禁使用本数据集的任何外部副本或变体。**

 违反任何一条，你的模型将被罚去手动给 100000000 条实验数据抄电表。

数据格式（CSV，看一眼就懂）

train.csv

列说明

维度	列名	类型	含义
 负载	lambda_qps	float	请求到达率，-1 表示离线批处理
 负载	scenario	str	场景： offline / server_low / server_high
 负载	avg_prompt_tokens	float	平均每条请求的输入 Token 数
 负载	avg_generation_tokens	float	平均每条请求的输出 Token 数
 模型	total_b_params	float	总参数量（十亿）
 模型	num_layers	int	Transformer 层数
 模型	hidden_size	int	隐藏层维度
 模型	model_type	str	架构家族（llama / qwen2 / mistral 等）
 硬件	memory_size_gb	float	GPU 显存容量 (GB)
 标签	gpu_power_draw_watts	float	预测目标1 ：平均功耗 (W)
 标签	avg_e2e_latency_seconds	float	预测目标2 ：端到端延迟 (s)
 标签	energy_efficiency_tokens_per_joule	float	预测目标3 ：能效比 (Token/J)

维度	列名	类型	含义
 标签	throughput_tokens_per_second	float	预测目标4： 吞吐量 (Token/s)

A.csv 和 B.csv

跟上面一样，**唯独少了最后 4 列标签**。因为那是你要预测的。

🔥 **注意：**训练集、A 榜、B 榜按 70:15:15 随机分割。**训练集含 GPU 不平衡**——稀缺的高端显卡（H200、H100等）样本较少，模拟真实场景中"买不起的卡数据也不多"。A/B 榜则完全均衡。

GPU	训练集保留	理由
Tesla T4 / L4 / L40S	100%	遍地都是，随便跑
RTX 3090 / 4090	70% / 60%	消费卡，顺便测测
Tesla V100	50%	老前辈了，且用且珍惜
A100 / A30	40%	贵，测一次心疼一次
H100 系列	25%	数据中心新贵，排队都排不上
H200 NVL	20%	顶级货，电费单比房租贵

😂 毕竟现实中谁能拿一打 H200 随便做实验啊？训练时吃不饱，考试还得全考——这才是真实世界的残酷。

提交格式（列名写错直接 0 分）

你需要提交两个预测文件：

- A_predict.csv
- B_predict.csv

每个文件包含 4 列，**顺序必须与测试集完全一致：**

```
gpu_power_draw_watts,avg_e2e_latency_seconds,energy_efficiency_tokens_per_joule,throughput_token
163.42,0.0487,27.68,4567.2
45.12,0.0125,18.34,892.1
```

⚠️ **不要加行索引，不要加 ID 列。** 评测脚本会按行号逐行比对，多一列 → 直接 0 分（冷酷但合理）。

🧠 Baseline 思路（超越它不算本事）

官方提供了一个 **Ridge 回归的极简基线**，预期 R^2 在 0.6~0.8 左右。
说实话，线性模型能有什么出息？你应该轻松吊打它。

📚 参考资料（助你成为 GPU 算命大师）

- **Watt Counts 论文**： *Watt Counts: An Empirical Study of GPU Power Consumption and Performance in LLM Inference*。（PDF 已打包进赛题压缩包，不用翻墙）
- **NVIDIA LLM Inference Performance Engineering**：官方技术博客系列，讲透了 GPU 推理的性能瓶颈。
- **Roofline Model**：经典性能分析框架，告诉你程序是卡在带宽还是算力上。
- **数据处理脚本**：赛题压缩包 `dataset/` 目录下的 `dataset-process.py` 和 `dataset-split.py`，展示了完整的特征工程 and 数据处理流程。

🎉 最后的话

你手中的数据来自 **真实的 GPU 集群**——从 Tesla T4 到 H200 NVL，从 GPT-2 124M 到 Gemma-3 27B，每一行都是真金白银的电费和机时烧出来的。

数据中心一年耗电量相当于一个小国家。如果你的模型能让功耗预测误差降低 5%，省下的电费够你买一打 H100。

但今天，你只需要让它学会：**看一份配置单，猜四个数字。**

Go, train, and may the R^2 be high! ⚡ 🍀

数据来源与许可

本题所使用的数据集基于 *Watt Counts* 论文（Watt Counts Subset）进行筛选与处理。我们对原始数据进行了特征工程处理，包括列表列解析聚合、GPU/模型元数据合并，以及目标变量计算。

© cyx012113 2026.