

蛋白质逆折叠挑战——结构到序列的重构

题目背景

蛋白质是生命活动的主要承担者，由 20 种氨基酸按特定顺序组成的长链分子，在自然状态下会自发折叠成特定的三维结构。理解氨基酸序列如何决定蛋白质的三维结构（即“蛋白质折叠问题”），一直是半个多世纪以来的科学难题。近年来，以 AlphaFold 为代表的深度学习模型在这一问题上取得了突破性进展——给定氨基酸序列，模型能够高精度地预测其折叠后的三维结构。

但自然还存在着另一个方向的谜题：如果给你一个三维结构，你能推断出它原本的氨基酸序列吗？这个问题被称为“**逆蛋白质折叠**”（Inverse Protein Folding），是蛋白质工程和药物设计的核心挑战。想象一下，科学家设计出一种理论上能完美结合某个致病靶点的蛋白质支架，但不知道应该由哪些氨基酸来搭建——逆折叠算法就是那把“解码”的钥匙，帮助我们找到能折叠成目标结构的氨基酸序列。其实际意义深远：在靶向癌症治疗中，逆折叠技术可用于设计高亲和力的抗体药物；在合成生物学中，它帮助创造自然界不存在的新酶，用于生物燃料生产或塑料降解；在疫苗开发中，它使科学家能够基于病毒表面结构设计出稳定性更高的免疫原。

本题的任务是：给定蛋白质三维结构中各个残基（氨基酸单元）的空间坐标，预测每个位置上应该放置哪种氨基酸。**评估指标只采用 F_2 分数（F2 Score）**，关注在罕见氨基酸类别上的预测表现——因为某些氨基酸在自然蛋白质中出现频率较低，但它们在药物设计中往往扮演关键角色。

题目描述

蛋白质由氨基酸序列构成，每个氨基酸残基包含一个 α -碳原子 (C_α)。在三维空间中，蛋白质的主链骨架可以通过这些 C_α 原子的三维坐标 (x, y, z) 来描述。逆折叠问题的目标正是：根据这些 C_α 原子的位置关系，预测每个位置上应该放置哪一种氨基酸。

在本题中，你需要完成以下任务：

1. 搭建一个模型；
2. 输入：蛋白质的 C_α 原子坐标序列；
3. 输出：每个位置上的氨基酸类别（20 种标准氨基酸）；
4. 模型训练与预测；
5. **最终排名仅依据模型对 B 榜数据集预测结果与 Ground Truth 的 F_2 分数。**

每个蛋白质的长度（残基数量）为 L ，坐标数据形状为 $L \times 3$ 。氨基酸类别使用 0 ~ 19 进行编码，分别对应 20 种氨基酸。

数据集

本题数据来源于 CATH 4.4 非冗余数据集（序列相似度 $\leq 40\%$ ），经预处理后形成三个 CSV 文件。蛋白质的长度 L 分布在 50 到 800 之间，平均长度约为 200。**每个样本已移除缺失 C_α 坐标的残基**，因此 CSV 文件中的坐标序列与氨基酸标签序列长度完全一致，且每个残基都有完整的三维坐标。

文件说明

- train.csv**：训练集，包含 30000 个样本，提供完整的坐标和氨基酸标签；
- A.csv**：A 榜测试集，包含 2000 个样本，仅提供坐标，标签不公开，得分不公开，用于模型选择；
- B.csv**：B 榜测试集，包含 1938 个样本，仅提供坐标，标签不公开，得分不公开，比赛结束后统一公布得分。

CSV 格式

每个 CSV 文件采用逗号分隔，UTF-8 编码，表头为列名。

train.csv 的列：

列名	数据类型	描述
domain_id	string	蛋白质结构域的唯一标识符（如 12asA00，区分大小写）
coords	string	所有 C_α 原子的三维坐标，按顺序展平为 $x_1,y_1,z_1,x_2,y_2,z_2,\dots,x_L,y_L,z_L$ 的逗号分隔字符串，每个坐标保留 3 位小数
labels	string	每个残基对应的氨基酸类别编码（0 ~ 19），按顺序以逗号分隔，例如 5,12,3,19,1,...

A.csv 和 B.csv 的列：

列名	数据类型	描述
domain_id	string	蛋白质结构域的唯一标识符（如 12asA00，区分大小写）
coords	string	所有 C_α 原子的三维坐标，按顺序展平为 $x_1,y_1,z_1,x_2,y_2,z_2,\dots,x_L,y_L,z_L$ 的逗号分隔字符串，每个坐标保留 3 位小数

注意：测试集文件不包含 labels 列，选手需要自行预测每个样本每个位置的氨基酸类别，并按照提交格式要求输出结果。

氨基酸类别编码表

编码	氨基酸	三字母	单字母
0	丙氨酸	Ala	A
1	半胱氨酸	Cys	C
2	天冬氨酸	Asp	D
3	谷氨酸	Glu	E
4	苯丙氨酸	Phe	F
5	甘氨酸	Gly	G
6	组氨酸	His	H
7	异亮氨酸	Ile	I
8	赖氨酸	Lys	K
9	亮氨酸	Leu	L
10	甲硫氨酸	Met	M
11	天冬酰胺	Asn	N
12	脯氨酸	Pro	P
13	谷氨酰胺	Gln	Q
14	精氨酸	Arg	R
15	丝氨酸	Ser	S
16	苏氨酸	Thr	T
17	缬氨酸	Val	V
18	色氨酸	Trp	W
19	酪氨酸	Tyr	Y

可直接在代码中使用的类别转换表：

```
aa2id = {
    'A': 0, 'C': 1, 'D': 2, 'E': 3, 'F': 4, 'G': 5, 'H': 6, 'I': 7, 'K': 8, 'L': 9,
    'M': 10, 'N': 11, 'P': 12, 'Q': 13, 'R': 14, 'S': 15, 'T': 16, 'V': 17, 'W': 18, 'Y': 19
}
id2aa = {
    0: 'A', 1: 'C', 2: 'D', 3: 'E', 4: 'F', 5: 'G', 6: 'H', 7: 'I', 8: 'K', 9: 'L',
    10: 'M', 11: 'N', 12: 'P', 13: 'Q', 14: 'R', 15: 'S', 16: 'T', 17: 'V', 18: 'W', 19: 'Y'
}
```

评估指标

本题采用 F_2 分数（F2 Score） 作为唯一评价指标。 F_2 分数是精确率（Precision）和召回率（Recall）的加权调和平均，其中召回率的权重是精确率的 4 倍，定义为：

$$F_2 = (1 + 2^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(2^2 \cdot \text{Precision}) + \text{Recall}} = 5 \cdot \frac{\text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

F_2 分数更关注召回率，即希望模型尽可能多地找出正确的氨基酸（尤其是那些低频但重要的类别），对漏报的惩罚比误报更严厉。这一指标反映了蛋白质逆折叠的实际需求：**漏掉一个关键的功能位点，可能导致整个蛋白质失效；但偶尔预测错一个非关键位置，蛋白质可能还能正常工作。**

计算方式：对测试集中每个蛋白质样本，分别计算每个氨基酸类别的精确率和召回率，然后计算该类别的 F_2 分数；最后对所有类别取 **宏平均（macro average）**，得到该样本的 F_2 分数。所有样本的 F_2 分数再取算术平均作为最终评测指标。若某个类别在样本中未出现，则跳过该类（不参与该样本的宏平均）。

提交格式

选手需要对 A.csv 和 B.csv 分别生成对应的预测结果文件，命名为 A_predict.csv 和 B_predict.csv 。每个预测文件必须包含以下两列：

列名	数据类型	描述
domain_id	string	与原始测试文件中的 domain_id 完全一致
predictions	string	每个残基预测的氨基酸类别（0 ~ 19），按顺序以逗号分隔，长度必须与原始 coords 列中的残基数（即坐标三元组的个数）相同

注意：预测结果的长度必须严格等于该蛋白质的残基数量 L ，否则该条数据不得分。

约束条件

1. 不得使用任何预训练模型权重（包括但不限于 EfficientNet、ResNet 等图像预训练模型，以及蛋白质语言模型如 ESM、ProtBERT、AlphaFold 等）。参赛者必须从随机初始化开始训练自己的模型，但可以使用 EfficientNet、ResNet 等模型的**框架代码**（即网络结构）；
2. 不得调用非 NOAI 官方提供的第三方库，包含但不限于 `mmproteo`、`capipy`；
3. 不得调用外部 LLM API（如 GPT、Claude 等）进行预测或辅助生成特征；
4. 请合理设计模型参数量（建议 10^6 以内）和训练时间（建议不超过 10 分钟）；
5. 提交内容：A_predict.csv 和 B_predict.csv 两个文件。

参考资料

- CATH 4.4 数据库论文：Waman, V. P., et al. (2025). CATH v4.4: major expansion of CATH by experimental and predicted structural data. *Nucleic Acids Research*, 53(D1), D348–D355. doi:[10.1093/nar/gkae1087](https://doi.org/10.1093/nar/gkae1087)，包含在数据集压缩包中；
- 逆折叠相关方法：PiFold, ProteinMPNN 等（可自行查阅 ArXiv 预印本）。

数据来源与许可

本题所使用的数据集基于 CATH 4.4 非冗余数据集（Waman et al., 2025）进行筛选与处理。原始 CATH 4.4 数据由 [UCL 研究团队](#) 发布，采用 [CC BY 4.0](#)。

我们对原始数据进行了以下处理：移除缺失 C α 坐标的残基，并将序列坐标和氨基酸标签按样本整理为 CSV 格式。

本题目的文本、题目设计及数据集衍生部分由 [cyx012113](#) 创作，整体采用 [CC BY-NC-SA 4.0](#) 许可。这意味着你可以自由分享、改编这道题目，但必须给出适当署名、不得用于商业目的，且任何改编作品必须采用相同的许可证。

- 原始 CATH 4.4 许可：<https://creativecommons.org/licenses/by/4.0>
- 本项目许可：<https://creativecommons.org/licenses/by-nc-sa/4.0>