



逆蛋白质折叠挑战：当 AI 学会“看图猜

NOAI 2026

Inverse Folding

“给你一张蛋白质的 3D 自拍，AI 居然能猜出它原来长啥样？”

——没错，这就是 **逆蛋白质折叠**。就像看到一栋摩天大楼的建筑图纸，反推需要多少吨钢材和玻璃。



A C D E F G H
I K L M N P Q
R S T V W Y ?



“从结构到序列，就像从脚印推测动物——但这次是 AI 上场！”



题目简介

你拿到了一份 **蛋白质的 3D 骨架坐标**（只有 C_α 原子的位置），你的任务是 **猜出每个位置上原本是哪种氨基酸**。

这就是 **逆蛋白质折叠**（Inverse Protein Folding）——蛋白质设计领域的“读心术”。

- **输入**： L 个点的 (x, y, z) 坐标（ L 在 50 ~ 800 之间）
- **输出**：每个点对应的氨基酸编号（0 ~ 19，共 20 种）
- **数据来源**：CATH 4.4 非冗余数据集（已贴心剔除缺失坐标的残基）
- **训练集**：30000 个样本，提供坐标 + 标签
- **A 榜测试集**：2000 个样本，只有坐标（用来悄悄验证你的模型）
- **B 榜测试集**：1938 个样本，只有坐标（最终排名靠它）



温馨提示：不要试图用肉眼观察坐标猜氨基酸——那是超人的工作。让神经网络替你打工吧。

评分标准： F_2 分数（召回率狂喜）

我们不玩准确率那种“及格万岁”的游戏。

F_2 分数把召回率的权重拉满（精确率:召回率 = 1 : 4），意味着：

-  多找出几个稀有的氨基酸（比如色氨酸W、半胱氨酸C）比少犯错更重要
-  漏掉一个关键残基 → 扣大分（就像忘记放盐的菜，没法补救）

公式长这样（别怕，代码里有现成的）：

$$F_2 = 5 \cdot \frac{\text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

最终成绩 = 所有样本的 F_2 分数取平均（每个样本内部先对20类取宏平均）。

 **目标：**让你的模型像“蛋白质侦探”，宁可多抓几个嫌疑人，也不能放走真凶。

约束条件（“禁止令”）

1.  **不准用预训练模型**（ESM、AlphaFold、ResNet50... 通通不许）。你必须从零开始训练，但可以用它们的 **网络结构** 当参考。
2.  **不准调用外部 LLM API**（GPT、Claude：谢谢，我们不约）。
3.  **不准使用第三方妖艳库**（比如 mmproteo 、 capipy ）。
4.  **训练时间 ≤ 10 分钟**（T4 显卡上，超过 10 分钟会被评委笑）。
5.  **参数量 $\leq 1^6$** （别堆几亿参数，T4 会哭）。

 违反以上任意一条，你的模型会被罚去折叠 100000000 个错误折叠的蛋白质。

数据格式（CSV，简单粗暴）

train.csv 长这样

domain_id	coords	labels
12asA00	12.345, 23.456, 34.567, ...	5, 12, 3, 19, 1, ...

- coords : $x_1, y_1, z_1, x_2, y_2, z_2, \dots$ (每个坐标保留 3 位小数)
- labels : 0 ~ 19 的数字串, 长度 = 残基数

A.csv 和 B.csv

只有 domain_id 和 coords , 没有 labels (因为要你自己猜)。

🚀 **注意**: 所有样本已经移除了缺失坐标的残基, 所以 coords 和 labels 组数永远一致。不用操心 mask 了, 省心!

🚀 提交格式

你需要输出两个文件:

- A_predict.csv
- B_predict.csv

每个文件包含两列:

domain_id	predictions
12asA00	5,12,3,19,1,...

- predictions : 预测的类别编号 (0 ~ 19), 长度必须和原文件中的残基数相等。
- **长度不对齐** → 该条数据直接0分 (残酷但公平)。

💡 小贴士: 用 `len(coords.split(','))//3` 算出残基数, 然后输出同样长度的预测串。

💡 Baseline 思路 (给你打个样)

我们提供了一个 **极简基线模型** (独立残基 MLP), 它把每个氨基酸当成孤立的点, 只用它的 (x, y, z) 坐标分类。

预期 F_2 分数 < **0.3** (相当于盲猜), 你可以轻松超越它。

给点提示 (看看就好)

改进方向 (由易到难):

1. 加入 **相对位置编码**（让模型知道谁挨着谁）
2. 用 **图神经网络**（把每个残基和空间最近的 K 个邻居连起来）
3. 提取 **旋转平移不变特征**（距离、二面角、局部方向）
4. 用 **Transformer** 捕捉长程依赖（注意：T4 显存有限，别太贪心）

🤖 如果你能想到用 **SE(3)-等变网络**，评委可能会给你鼓掌。

参考资料（助你成为逆折叠大师）

- [CATH 4.4 论文](#)（数据集来源，记得引用）
- PiFold、ProteinMPNN（ArXiv 上随便搜，看懂算你赢）
- PyTorch 官方教程（不会PyTorch？先去学两天）

最后的话

逆折叠 不仅是算法竞赛，更是通往 **AI设计新蛋白质** 的大门。

也许你的模型将来能设计出 **分解塑料的酶**、**靶向癌症的药物**，甚至 **不会让人过敏的蛋白质**。

但今天，你只需要让它学会 **从坐标猜氨基酸**。

Go, build, and let the F_2 be with you! 🍀

数据来源与许可

本题所使用的数据集基于 CATH 4.4 非冗余数据集（Waman et al., 2025）进行筛选与处理。原始 CATH 4.4 数据由 [UCL 研究团队](#) 发布，采用 [CC BY 4.0](#)。

我们对原始数据进行了以下处理：移除缺失 C α 坐标的残基，并将序列坐标和氨基酸标签按样本整理为 CSV 格式。

本题目的文本、题目设计及数据集衍生部分由 [cyx012113](#) 创作，整体采用 [CC BY-NC-SA 4.0](#) 许可。这意味着你可以自由分享、改编这道题目，但必须给出适当署名、不得用于商业目的，且任何改编作品必须采用相同的许可证。

- 原始 CATH 4.4 许可：<https://creativecommons.org/licenses/by/4.0>
- 本项目许可：<https://creativecommons.org/licenses/by-nc-sa/4.0>