

宇宙探针：基于测光数据的恒星-星系-类星体分类挑战

题目背景

在现代天文学中，大视场巡天项目每晚产生海量的天体图像与测光数据。以斯隆数字化巡天（Sloan Digital Sky Survey, SDSS）为代表的第五代光谱巡天（SDSS-V），已累计发布超过 4.6×10^6 条有光谱确认的天体记录，为研究宇宙大尺度结构、星系演化以及超大质量黑洞的活动提供了无可替代的数据宝藏。

然而，面对数十亿计的天体候选体，光谱观测的昂贵与耗时使得只有极少数天体能够获得确切的类型标签。AI for Science 的浪潮为这一困境带来了转机：通过海量有光谱标签的天体测光数据训练分类模型，天文学家能够高效地从巡天图像中筛选出高价值的观测目标（尤其是罕见的类星体），极大提升后续大型望远镜的观测效率。

本题的灵感来源于 ArXiv 最新天文学研究：“基于机器学习与符号回归的 SDSS 天体自动分类”（参考论文见后）。你的任务是扮演“**数字天文学家**”，利用天体在五个光学波段的测光特征（星等），构建模型将其精准划分为三类：**恒星（STAR）**、**星系（GALAXY）** 和 **类星体（QSO）**。

类星体是遥远的活动星系核，中心通常藏匿着快速增长的超大质量黑洞，是研究早期宇宙的关键探针。然而，它们在数据集中占比极低（约 18.8%），且极易与恒星或致密星系混淆。**本题仅以 F_2 分数作为评价指标**，正是为了强调召回率（Recall）的重要性——**漏掉一个类星体的科学代价远高于误判几个普通天体**。

题目描述

你需要完成以下任务：

- 理解并处理 SDSS 测光星表数据；
- 设计并训练一个分类模型；
- 输入：天体的五个波段（ u, g, r, i, z ）模型星等（`modelMag`）；
- 输出：该天体所属类别（`GALAXY`，`STAR`，`QSO`）；
- 最终排名仅依据模型在 B 榜测试集上预测结果与 Ground Truth 的 F_2 分数。**

数据集共计 90000 条记录，每条记录均来自 SDSS 光谱确认的天体，具有极高的标签可信度。数据已划分为训练集、A 榜测试集与 B 榜测试集，具体划分见下文。

数据集

本题数据基于 **SDSS Data Release 17** 的公开星表，使用 PhotoPrimary 视图与 SpecObj 光谱表关联，筛选出具有光谱分类标签 GALAXY、STAR 或 QSO 的天体。原始数据总量为 4,618,598 条，按比例随机分割为以下 CSV 文件。

文件说明

文件名	样本数量	内容描述
train.csv	30000	训练集，包含特征列与标签列
A.csv	30000	A 榜测试集，仅包含特征列（无标签）
B.csv	30000	B 榜测试集，仅包含特征列（无标签）
A_ground_truth.csv	30000	A 榜答案（仅用于本地验证，不公开评分）
B_ground_truth.csv	30000	B 榜答案（最终排名依据，不公开）

CSV 格式

所有 CSV 文件采用逗号分隔，UTF-8 编码，首行为列名。

train.csv 的列：

列名	数据类型	描述
objid	integer	天体在 SDSS 数据库中的唯一标识符（64 位整数）
ra	float	赤经（Right Ascension），单位：度
dec	float	赤纬（Declination），单位：度
modelMag_u	float	<i>u</i> 波段（紫外）模型星等
modelMag_g	float	<i>g</i> 波段（绿光）模型星等
modelMag_r	float	<i>r</i> 波段（红光）模型星等
modelMag_i	float	<i>i</i> 波段（近红外）模型星等
modelMag_z	float	<i>z</i> 波段（近红外）模型星等
type	string	天体光谱分类标签，取值为 GALAXY、STAR、QSO

A.csv 与 B.csv 的列：

列名	数据类型	描述
objid	integer	天体唯一标识符
ra	float	赤经（度）
dec	float	赤纬（度）
modelMag_u	float	<i>u</i> 波段模型星等
modelMag_g	float	<i>g</i> 波段模型星等
modelMag_r	float	<i>r</i> 波段模型星等
modelMag_i	float	<i>i</i> 波段模型星等
modelMag_z	float	<i>z</i> 波段模型星等

注意：测试集文件中**不包含** type 列。选手需自行预测每个天体的类别。

类别标签说明

标签	含义	科学描述
GALAXY	星系	包含数千亿颗恒星的庞大引力束缚系统
STAR	恒星	银河系内的炽热等离子体球，通过核聚变发光
QSO	类星体	遥远的活动星系核，中心超大质量黑洞吸积物质产生巨大能量

训练集与测试集均**保持了与原始数据一致的类别比例**，因此该任务是一个典型的**不平衡多分类问题**。

评估指标

本题采用 F_2 分数（**F2 Score**） 作为唯一评价指标。 F_2 分数是精确率（Precision）和召回率（Recall）的加权调和平均，其中召回率的权重是精确率的 4 倍，定义为：

$$F_2 = (1 + 2^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(2^2 \cdot \text{Precision}) + \text{Recall}} = 5 \cdot \frac{\text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

F_2 分数赋予召回率更高的权重，意味着模型 **“宁可错判，不可漏判”**，尤其需要尽可能多地找出稀有的 qso（类星体）样本。因为在实际天文巡天中，漏掉一个高红移类星体可能导致错失一次重要的早期宇宙发现机会。

计算方式：对测试集所有样本计算混淆矩阵，然后对三个类别（ GALAXY ， STAR ， QSO ）分别计算精确率与召回率，进而计算各类别的 F_2 分数，最后采用 **加权平均（weighted average）** 得到最终的 F_2 分数（权重为各类别在测试集中的真实样本数比例）。

提交格式

选手需对 A.csv 和 B.csv 分别生成预测结果文件，命名为 A_predict.csv 和 B_predict.csv 。

每个预测文件必须包含以下两列：

列名	数据类型	描述
objid	integer	与原始测试文件中的 objid 完全一致
type	string	预测的天体类别，取值必须为 GALAXY 、 STAR 或 QSO

提交文件示例：

```
objid,type
1237645879551000764,GALAXY
1237645879551066262,STAR
1237645879562862699,QSO
```

注意： objid 的顺序需与测试文件保持一致，行数必须严格相等，否则该提交无效。

约束条件

- 不得使用任何在天文或通用图像数据集上预训练的模型权重（如 ImageNet 预训练的 CNN，或已在天文数据上预训练的网络）。模型必须从随机初始化开始训练；
- 仅可使用 NOAI 考纲所允许的第三方库（如 numpy ， pandas ， scikit-learn ， torch ， matplotlib 等）；
- 不得调用外部大模型 API（如 GPT、Claude 等）进行预测或特征生成；
- 合理控制模型复杂度与训练时间（建议参数量不超过 10^6 ，单次训练时间不超过 10 分钟）；
- 最终需提交 A_predict.csv 与 B_predict.csv 两个文件。

参考资料

本题数据来源于 SDSS-V 的 Data Release 17，相关数据处理与分类方法受以下 ArXiv 论文启发：

- **论文：**Abdurro'uf, et al. (2022). *The Seventeenth Data Release of the Sloan Digital Sky Surveys: Complete Release of MaNGA, MaStar, and APOGEE-2 Data*. *The Astrophysical Journal Supplement Series*, 259(2), 35.

ArXiv 链接: <https://arxiv.org/abs/2112.02026>

(该论文 PDF 已包含在赛题压缩包中)

- **分类任务参考：**Clarke, A. O., et al. (2020). *Identifying galaxies, quasars, and stars with machine learning: A new catalogue of classifications for 111 million SDSS sources without spectra*. *Astronomy & Astrophysics*, 639, A84.

ArXiv 链接: <https://arxiv.org/abs/1909.10963>

选手可参考上述论文了解 SDSS 数据背景与星体分类的科学意义，但**不可直接使用论文中提供的预训练模型或外部代码库**。