



宇宙探针：当 AI 被拉去当天文学家



NOAI 2026

AI for Science Cosmic Classifier

“给你五个波段的亮度数据，你能区分出星星、星系和黑洞贪吃鬼吗？”

——欢迎来到 **SDSS 星体分类挑战**，让你足不出户，体验一把 **数字天文学家** 的日常。



“五个数字定乾坤——AI 天文学家上岗记”

“从五个波段的亮度到宇宙三大‘物种’，AI 说：这比识别猫狗刺激多了。”



题目简介

你手中握有 **460 万条** 来自斯隆数字化巡天（SDSS）的真实天文数据。每一条数据都是一个天体的“体检报告”——五个波段的星等（亮度值），外加一个 **金标准光谱标签**（`GALAXY` / `STAR` / `QSO`）。你的任务极其纯粹：

只看五个数字，猜出它是何方神圣。

- **输入**：五个浮点数——`u`, `g`, `r`, `i`, `z` 波段的模型星等（越亮数字越小）。
- **输出**：三类之一——`GALAXY`（星系）、`STAR`（恒星）、`QSO`（类星体，黑洞吸积盘发光版）。
- **训练集**：600000 条，坐标 + 星等 + 标签全给你。
- **A 榜测试集**：600000 条，只有星等，给你悄悄验证模型。
- **B 榜测试集**：600000 条，只有星等，最终排名全靠它。



温馨提示：不要试图肉眼区分——`u - g` 差 0.5 和差 1.5 的区别，比口红色号还难辨。请把这事交给神经网络。

由于数据过于强大，原始数据 baseline（随机森林）达到 0.9700 分，出题者被迫加上了不平衡，以削弱 baseline。



评分标准： F_2 分数——类星体一个都不能少

天文学家有句行话：“宁可错杀一千，不可放过一个类星体。”

因为 **类星体** 是宇宙早期的信使，漏掉一个就意味着错失一次窥视远古宇宙的机会。

F_2 分数完美贯彻这一精神：召回率的权重是精确率的 **4 倍**。公式如下（别怕，`sklearn` 里一行搞定）：

$$F_2 = 5 \cdot \frac{\text{Precision} \cdot \text{Recall}}{4 \cdot \text{Precision} + \text{Recall}}$$

-  **多找出几个 QSO** → 加分
-  **漏掉 QSO** → 扣大分
-  **把星系错判成恒星** → 还好，天文学家表示情绪稳定

最终分数 = 对三类（`GALAXY`，`STAR`，`QSO`）分别计算 F_2 ，然后按测试集真实类别比例 **加权平均**。

 **目标**：让你的模型成为“**类星体猎手**”，宁可多报十次假警，也不放过一个真凶。

约束条件（“禁止做这些，否则把你发配到柯伊伯带”）

1.  **不准用预训练权重**（ImageNet 上训过的 ResNet？不行。天文数据集上训过的任何模型？也不行。）模型必须 **从随机初始化** 开始训练。
2.  **不准调戏大模型 API**（GPT、Claude、文心一言……它们不懂天文，问了也白问）。
3.  **只允许 NOAI 考纲内的库**（`numpy`，`pandas`，`scikit-learn`，`torch`，`matplotlib` 等，别掏出来路不明的第三方轮子）。
4.  **训练时间 ≤ 10 分钟**（在 T4 上跑，超时会被当成死循环杀掉）。
5.  **参数量 $\leq 10^6$** （T4 显存有限，别把它当 H100 使唤）。

 违反任何一条，你的模型将被流放去处理 100000000 条无标签的暗弱天体测光数据。

数据格式（CSV，清爽不油腻）

train.csv 列说明

列名	类型	含义
objid	int	SDSS 数据库唯一 ID（断点续传好帮手）
ra	float	赤经（经度），单位度
dec	float	赤纬（纬度），单位度
modelMag_u	float	<i>u</i> 波段（紫外）星等
modelMag_g	float	<i>g</i> 波段（绿光）星等
modelMag_r	float	<i>r</i> 波段（红光）星等
modelMag_i	float	<i>i</i> 波段（近红外）星等
modelMag_z	float	<i>z</i> 波段（近红外）星等
type	string	金标准标签： GALAXY 、 STAR 、 QSO

A.csv 和 B.csv

跟上面一样，**唯独少了 type 列**。因为这是你要预测的答案。

✦ **注意：**数据集是 **极度不平衡** 的——星系占 $\sim 60\%$ ，恒星 $\sim 21\%$ ，类星体只有 $\sim 19\%$ 。你的模型不能只会猜“星系”，那样 F_2 会惨不忍睹。

提交格式（别写错列名，否则 0 分警告）

你需要提交两个预测文件：

- A_predict.csv
- B_predict.csv

每个文件必须包含以下两列：

列名	类型	描述
objid	int	必须与原始测试文件中的 objid 一模一样
type	string	你的预测结果，取值为 GALAXY、STAR 或 QSO

示例：

```
objid,type
1237645879551000764,GALAXY
1237645879551066262,STAR
1237645879562862699,QSO
```

⚠️ 行数必须与测试文件一致，objid 的顺序也不能变。
评测脚本会逐行比对，顺序一乱 → 直接 0 分（残酷但有效）。

💡 Baseline 思路（看看就行，超越它易如反掌）

官方提供了一个“全猜星系”的摆烂基线，预期 $F_2 \approx 0.47$ 。
连这都打不过的话……建议重新读一遍 sklearn 文档。

改进方向（按难度排序）：

- 1. **特征工程**：构造颜色指数（如 `u-g`，`g-r`，`r-i`，`i-z`）——天文学家用了都说好。
- 2. **处理不平衡**：`class_weight='balanced'` 或者上 SMOTE 过采样。
- 3. **集成学习**：随机森林、XGBoost、LightGBM——三幻神总能给你惊喜。
- 4. **简单神经网络**：3 层 MLP + BatchNorm + Dropout，轻松上 0.90。
- 5. **进阶**：把 `ra` 和 `dec` 用球面谐波编码（但没必要，测光特征已经够用）。

😏 如果你能整出一个 **Transformer** 来处理五个数字，评委可能会露出“你在逗我”的表情，但依然给你分。

📚 参考资料（助你成为天文 AI 大师）

- **SDSS DR17 官方论文**：Abdurro'uf et al. (2022). *The Seventeenth Data Release of the Sloan Digital Sky Surveys*. ApJS, 259, 35.

ArXiv 链接: <https://arxiv.org/abs/2112.02026>

(PDF 已打包进赛题压缩包, 不用自己翻墙下载)

- **星体分类经典 ML 论文:** Clarke et al. (2020). *Identifying galaxies, quasars, and stars with machine learning*. A&A, 639, A84.

ArXiv 链接: <https://arxiv.org/abs/1909.10963>

(看看前辈们是怎么用随机森林打下江山的)

最后的话

你手中的数据来自 **SDSS 望远镜**——它每晚扫描数千平方度天空, 捕捉数十亿光年外的星光。
今天, 你用几行代码就能从这些光点中分辨出 **恒星、星系与黑洞的怒吼**。

也许某一天, 你的模型会帮助天文学家发现一颗 **宇宙诞生之初的类星体**, 或者一个 **正在并合的特殊星系**。

但今天, 你只需要让它学会: **看五个数字, 猜对三种天体**。

Go, train, and may the F_2 be with you! 🚀🌟

© cyx012113 2026